REPORT FINALE – Analisi delle Recensioni Booking.com

1. Introduzione

Nel panorama contemporaneo del settore *travel & hospitality*, la reputazione digitale ha smesso di essere un semplice indicatore di gradimento per diventare una variabile economica fondamentale. Le recensioni online non sono solo narrazioni dell'esperienza dell'ospite, ma asset strategici che influenzano direttamente l'elasticità della domanda e le performance finanziarie delle strutture ricettive. In questo scenario, piattaforme leader come **Booking.com** agiscono come ecosistemi di dati ad alta densità, fondamentali per comprendere le dinamiche della *customer experience* su scala globale.

Il presente studio si basa sull'analisi del dataset pubblico **"515K Hotel Reviews Data in Europe"**, reperito tramite la piattaforma **Kaggle** (disponibile all'indirizzo: Kaggle - Hotel Reviews Dataset). Il dataset contenente circa **515.000 recensioni relative a 1.493 hotel europei**, di fascia alta situati nelle principali destinazioni europee. L'arco temporale analizzato copre il biennio **2015-2017**, offrendo una profondità storica ideale per l'identificazione di trend consolidati. Le variabili analizzate includono:

- Indicatori quantitativi (punteggi numerici, conteggio parole).
- Dati geolocalizzati (coordinate e indirizzi degli hotel).
- Informazioni demografiche (nazionalità dei recensori).
- Segmentazione qualitativa (testi separati per feedback positivi e negativi).

L'analisi si propone di decodificare la complessità di questi dati attraverso un approccio analitico rigoroso, focalizzandosi su quattro pilastri fondamentali:

1. **Dinamiche Temporali:** Identificazione della stagionalità dei flussi di recensioni per ottimizzare le finestre di gestione della reputazione.
2. **Segmentazione per Nazionalità:** Analisi del comportamento d'acquisto e della propensione al voto in base all'origine geografica, per calibrare strategie di marketing mirate.
3. **Benchmarking Urbano:** Valutazione comparativa delle performance competitive tra le diverse capitali europee coinvolte (Londra, Parigi, Amsterdam, Vienna, Milano e Barcellona).
4. **Analisi della Correlazione Testo-Punteggio:** Studio della relazione tra la lunghezza/contenuto del feedback e il punteggio assegnato, utile a identificare i driver critici di soddisfazione e insoddisfazione.

L'output finale è concepito come uno strumento di supporto decisionale per il **Revenue Management**. L'obiettivo è fornire insight che non si limitino alla descrizione del passato, ma che offrano basi solide per l'ottimizzazione del **pricing**, del **posizionamento competitivo** e della **gestione della reputazione online**.

2. Metodologia

Il processo di analisi è stato strutturato per gestire un volume di dati massivo tramite un'architettura che combina **Python** per il pre-processing e **SQL** per l'archiviazione e l'interrogazione complessa.

2.1 Protocollo Operativo e Workflow dei File

Per garantire l'integrità del dato e la corretta popolazione del database, i file devono essere utilizzati secondo la seguente sequenza logica:

1. **EDA_Cleaning.ipynb**: Pulizia iniziale del dataset grezzo (gestione decimali, valori nulli e normalizzazione) e generazione del file hotel_reviews_clean.csv.
2. **create_table.sql**: Definizione del database e creazione delle tabelle strutturate (hotel, hotel_stats, reviewers, reviews). In questa fase è stata creata anche una **tabella di supporto** per facilitare l'importazione massiva dei dati.
3. **import_csv.py**: Questo script Python è stato sviluppato per automatizzare e ottimizzare il caricamento dei dati dal file hotel_reviews_clean.csv verso il database SQL. L'utilizzo di uno script dedicato, basato sulla libreria pandas e motori di connessione (sqlalchemy), ha permesso di gestire in modo programmatico l'invio dei record alla tabella **"Supporto"**. Questa scelta è stata dettata dalla necessità di superare i limiti di timeout dei client SQL.
4. **Insert_data.sql**: Una volta popolata la tabella di supporto, questo file gestisce la fase di **Data Migration** interna al database. Attraverso istruzioni INSERT INTO ... SELECT, i dati sono stati smistati e normalizzati nelle tabelle definitive (hotel, hotel_stats, reviews e reviewers).
5. **analysis_queries.sql**: Esecuzione delle interrogazioni SQL per l'estrazione dei KPI e delle metriche aggregate.
6. **02_analysis_pandas_plots.ipynb**: Validazione dei risultati tramite Pandas e creazione della reportistica grafica finale.
7. **final_report.pdf**: Documento finale di sintesi che raccoglie i risultati dell'analisi, le visualizzazioni grafiche e le conclusioni tratte dal dataset processato.

2.2 Strategie di Gestione Big Data

Data la dimensione del dataset (oltre **515.000 recensioni**), il caricamento ha richiesto l'adozione di soluzioni tecniche specifiche per superare i limiti di memoria dei sistemi standard:

- **Architettura di Supporto:** È stata implementata una tabella intermedia denominata “Supporto”. Questo approccio ha permesso di importare i dati grezzi in un ambiente controllato prima di procedere alla loro distribuzione nelle tabelle normalizzate.
- **Caricamento a Blocchi (Chunking):** La tabella review, a causa delle sue dimensioni (circa 511.000 righe effettive dopo il cleaning), presentava criticità durante l'inserimento SQL. Il problema è stato risolto adottando una strategia di **caricamento incrementale**:
    - Inizialmente sono stati testati blocchi da **10.000** e **20.000** righe.
    - Una volta verificata la stabilità del sistema, il limite è stato ottimizzato a **50.000** righe per blocco, garantendo velocità e assenza di timeout o blocchi del server.

2.3 Pulizia e Trasformazione dei Dati (EDA)

La fase di **Exploratory Data Analysis (EDA)** e **Data Cleaning**, sviluppata nel notebook EDA_Cleaning.ipynb, è stata orientata alla costruzione di una base dati coerente, eliminando le

anomalie tecniche e strutturando le variabili in ottica di Business Intelligence. Di seguito vengono descritti i processi metodologici applicati.

A. Bonifica e Integrità del Dato

Il dataset originale (oltre 515.000 osservazioni) è stato sottoposto a una rigorosa operazione di bonifica per garantire l'affidabilità delle analisi successive:

- **Gestione dei Duplicati Tecnici:** L'ispezione approfondita ha rivelato la presenza di record perfettamente identici in tutte le dimensioni (testuali, temporali e numeriche). Tali righe, riconducibili a ridondanze infrastrutturali o errori di acquisizione, sono state rimosse sistematicamente. Questa operazione è stata essenziale per evitare l'inflazione artificiale dei volumi di recensioni e la conseguente distorsione delle medie dei punteggi.
- **Normalizzazione degli "Hidden Nulls":** È stata eseguita una scansione per identificare le celle contenenti solo spazi vuoti (" "), non riconosciute automaticamente come valori nulli. Attraverso un'operazione di *stripping* (pulizia degli spazi iniziali e finali), tali stringhe sono state convertite formalmente in NaN, garantendo una gestione trasparente delle lacune informative.
- **Trattamento dei Valori Mancanti:**
    - Per la **Geolocalizzazione**, data la bassa incidenza di mancanze (0,6%), si è optato per la rimozione dei record privi di coordinate per preservare la precisione di eventuali analisi cartografiche.
    - Per la **Nazionalità**, i valori mancanti sono stati riclassificati sotto la categoria esplicita *"Unknown"*, permettendo di mantenere l'integrità del campione statistico per le analisi di punteggio correlate.

B. Normalizzazione e Feature Engineering

Per trasformare il dataset in uno strumento di business, sono state ingegnerizzate nuove variabili strategiche:

- **Normalizzazione temporale:** La variabile review_date è stata convertita in formato *datetime*, permettendo l'estrazione di **Anno** e **Mese**. Contestualmente, la variabile days_since_review è stata trasformata da stringa a intero (formato *int*), rendendola utilizzabile per calcoli quantitativi sulla freschezza del feedback.
- **Mappatura geografica (Città e Nazione):** Dall'analisi della colonna hotel_address è emerso che l'estrazione basata sulla semplice posizione della stringa non era affidabile a causa dei diversi formati postali europei. È stata quindi implementata una logica di mappatura testuale per isolare con precisione:
    - Le sei **città core** (**Londra**, **Parigi**, **Amsterdam**, **Vienna**, **Barcellona** e **Milano**).
    - La **nazione di appartenenza** (hotel_country), fondamentale per aggregare i risultati a livello macro-economico e confrontare le medie dei punteggi tra i diversi mercati europei.
- **Engagement del cliente (review_length):** È stata creata una variabile derivata sommando il numero di parole dei feedback positivi e negativi. Questa metrica è fondamentale per pesare il "coinvolgimento" del cliente.

C. Preparazione per l'Ambiente SQL

In vista del caricamento nel database relazionale, si è proceduto alla **standardizzazione dei nomi delle variabili** adottando il formato *snake_case* (es. reviewer_score, hotel_city). Questa operazione garantisce la compatibilità con lo schema SQL e facilita l'interoperabilità tra gli script Python e le query di analisi.

2.4 Fase Analitica: Interrogazione SQL e Validazione Pandas

Una volta consolidato l'ambiente e popolato il database, il progetto è entrato nella fase di estrazione degli insight. Per garantire l'accuratezza dei risultati, è stato implementato un protocollo di **Cross-Environment Validation** (validazione tra ambienti diversi).

A. Data Mining tramite Query SQL

Utilizzando il file analysis_queries.sql, è stata interrogata la base dati per estrarre le metriche core. L'approccio SQL è stato fondamentale per gestire in modo efficiente il volume di oltre 515.000 record, focalizzandosi su cinque aree critiche:

1. **Dinamiche temporali:** Aggregazione per mese/anno per identificare i picchi di attività.
2. **Profiling demografico:** Analisi della distribuzione delle nazionalità e calcolo del peso percentuale dei mercati (es. la dominanza del mercato UK).
3. **Benchmarking competitivo:** Identificazione degli hotel con le migliori performance in termini di *Average Score* e volume di feedback.
4. **Clusterizzazione geografica:** Distribuzione della soddisfazione per città e nazione.
5. **Analisi quantitativa del testo:** Studio della correlazione tra la lunghezza delle recensioni e il punteggio assegnato.

B. Protocollo di Validazione e Double-Check (Pandas)

Per evitare errori di logica o "bias" nel codice, ho applicato una **validazione incrociata**. Ho replicato le stesse identiche analisi presenti in SQL all'interno del notebook 02_analysis_pandas_plots.ipynb.

- **Verifica di coerenza:** Il caricamento del file hotel_reviews_clean.csv tramite Pandas ha previsto un controllo preventivo dei tipi di dato, con la conversione della colonna review_date in formato *datetime* per garantire l'allineamento con le funzioni temporali di Python.
- **Coincidenza dei risultati:** Il confronto tra gli output SQL e quelli Pandas ha mostrato una **coincidenza totale (100%)** delle aggregazioni. Questo processo di validazione incrociata ha confermato che la logica di pulizia dei dati e le operazioni di calcolo non presentano bias tecnici.

C. Feature Engineering Avanzato e Clustering

Prima della fase di visualizzazione, sono state ingegnerizzate variabili aggiuntive per raffinare l'analisi:

- **Sentiment Score semplificato:** È stato creato un indicatore di sentiment pesando il rapporto tra parole positive/negative e la lunghezza totale del feedback, fornendo una dimensione qualitativa al dato puramente numerico.
- **Clustering delle performance:** Le città sono state classificate in cluster (Alto, Medio, Basso) in base allo score medio. L'analisi ha rivelato un'altissima densità nel cluster **Alto**, portando alla decisione di focalizzare la visualizzazione sulle micro-differenze statistiche tra le capitali.

D. Data Storytelling e Visualizzazione Scientifica

L'ultima fase ha visto la traduzione delle evidenze numeriche in asset visivi tramite Seaborn e Matplotlib, adottando un approccio di **visualizzazione scientifica**:

- **Analisi della varianza (Box Plots):** Per visualizzare non solo la media, ma la dispersione e gli *outliers* nei voti tra nazionalità diverse (es. il differente comportamento critico tra viaggiatori USA e UK).
- **Mappe di correlazione (Heatmaps):** Per quantificare il legame tra punteggio e verbosità della recensione.
- **Analisi dei trend:** Grafici a linee e istogrammi sovrapposti per monitorare l'evoluzione della stagionalità e la quota di mercato geografica lungo l'arco di tempo analizzato.

3. Risultati e Analisi dei Dati

In questa sezione vengono presentati i risultati ottenuti attraverso l'elaborazione dei dati. L'analisi segue la logica del workflow precedentemente descritto: i numeri estratti tramite query SQL e validati in Python costituiscono la base oggettiva su cui è stata costruita la successiva analisi grafica.

3.1 Analisi Quantitativa delle Interrogazioni

Le interrogazioni dirette sul database hanno permesso di mappare con estrema precisione le dinamiche operative e i profili degli utenti, fornendo evidenze oggettive che guidano la comprensione del mercato hospitality analizzato.

In prima istanza, l'analisi dei **volumi e dei picchi di attività** ha rivelato come l'afflusso di dati non sia solo massivo, ma anche soggetto a forti variazioni temporali. Un dato particolarmente significativo è emerso dall'analisi dei picchi: lo **Strand Palace Hotel** ha registrato il massimo carico operativo del dataset con 304 recensioni nel solo mese di Febbraio 2016. Questa evidenza suggerisce che le strutture di grandi dimensioni devono essere preparate a gestire una mole critica di feedback anche al di fuori dei tradizionali periodi di alta stagione. Parallelamente, l'andamento mensile ha mostrato una stabilità del punteggio medio (oscillante tra 8.19 e 8.55), a fronte di un volume di recensioni che ha costantemente superato le 20.000 unità mensili durante tutto il 2016.

Per quanto riguarda il profilo della **nazionalità dei recensori**, i dati evidenziano una polarizzazione verso il mercato britannico. Il **Regno Unito** non è solo la nazione leader per volume con 244.321 recensioni, ma rappresenta da solo il **47.72%** dell'intero dataset. Questo dato è cruciale per interpretare la reputazione globale delle strutture, poiché i viaggiatori UK mostrano una propensione al voto mediamente più generosa (8.48) rispetto alla categoria "Altri" (8.31). Al secondo e terzo posto si posizionano gli USA e l'Australia, che contribuiscono rispettivamente con 35.108 e 21.502 recensioni.

Spostando il focus sulle **performance degli hotel**, l'incrocio tra punteggio medio e consistenza statistica ha incoronato il **Ritz Paris** come benchmark di eccellenza, con uno score di 9.8 su 122 recensioni. Oltre ai vertici qualitativi, le query hanno permesso di effettuare una "Gap Analysis" tra il voto puntuale dell'utente e la media storica della struttura; tale scostamento si rivela uno strumento diagnostico fondamentale per intercettare tempestivamente eventuali crisi reputazionali o cali nella qualità percepita del servizio.

Dal punto di vista **geografico**, la distribuzione conferma la centralità di **Londra** con 262.298 recensioni, seguita da un blocco equilibrato composto da Barcellona, Parigi e Amsterdam. Tuttavia, l'analisi qualitativa ribalta la gerarchia dei volumi: **Vienna** si distingue come la città con il più alto indice di gradimento (8.57), seguita da Barcellona (8.55). Questo indica che, nel cluster lusso analizzato, le destinazioni con volumi leggermente inferiori riescono spesso a garantire una soddisfazione dell'ospite più elevata.

Infine, l'interrogazione sulla **lunghezza delle recensioni** ha fornito una conferma numerica a un'ipotesi psicometrica rilevante: esiste una **correlazione negativa (-0.38)** tra il punteggio e la verbosità del feedback. I dati dimostrano che un cliente insoddisfatto tende ad essere molto più analitico, scrivendo mediamente 55.57 parole per giustificare un voto basso, mentre l'ospite soddisfatto si limita a feedback più sintetici (31.67 parole).

3.2 Analisi Grafica e Interpretazione dei Trend

Dopo aver stabilito la base numerica, le visualizzazioni grafiche permettono di cogliere visivamente la forma dei trend e le distribuzioni statistiche del campione.

3.2.1 Dinamiche Temporali e Stagionalità

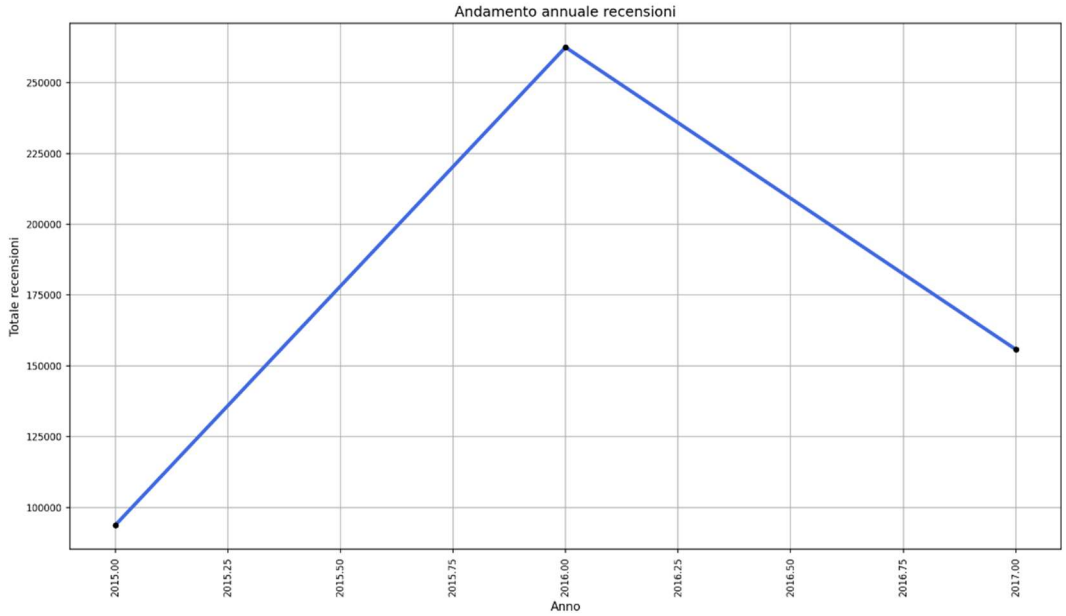

Figura 1. Line plot recensioni/anno

La *Figura 1* conferma il ruolo centrale del 2016 come anno cardine per la raccolta dati. È importante sottolineare che il calo visibile nel 2017 non riflette una flessione del mercato, ma è un artefatto tecnico dovuto alla chiusura della raccolta dati nel mese di agosto.

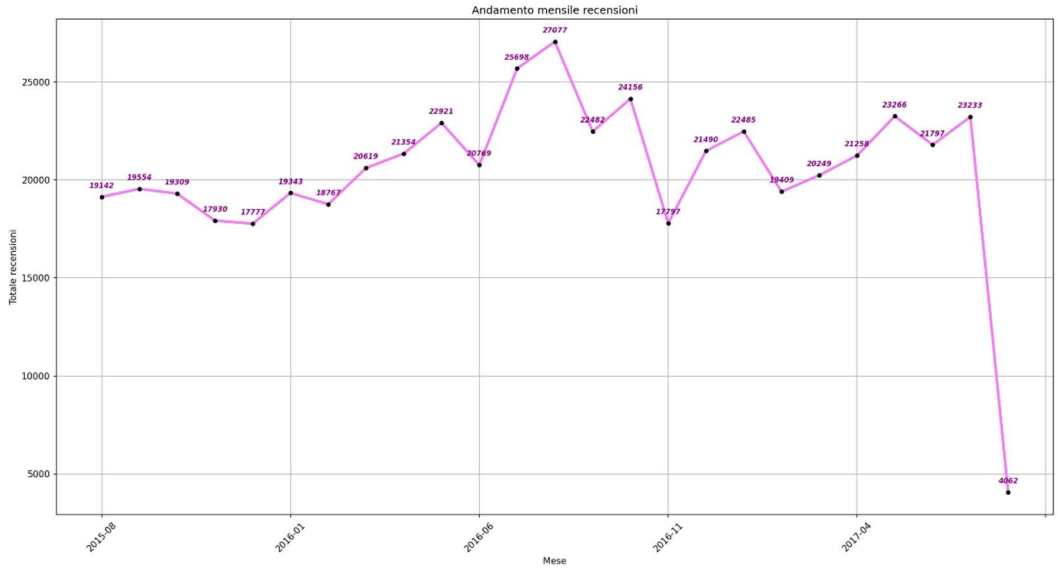

Figura 2. Line plot recensioni/mese

La scomposizione mensile (*Figura 2*) mette a nudo la forte componente stagionale tipica dell'hospitality europea. Il picco massimo di **Luglio 2016** (27.077 recensioni) e i volumi elevati della primavera/estate 2017 confermano che il flusso di feedback segue fedelmente i movimenti turistici stagionali, con flessioni fisiologiche nei mesi invernali come Novembre e Gennaio.

3.2.2 Comportamento di Voto e Mercati Chiave

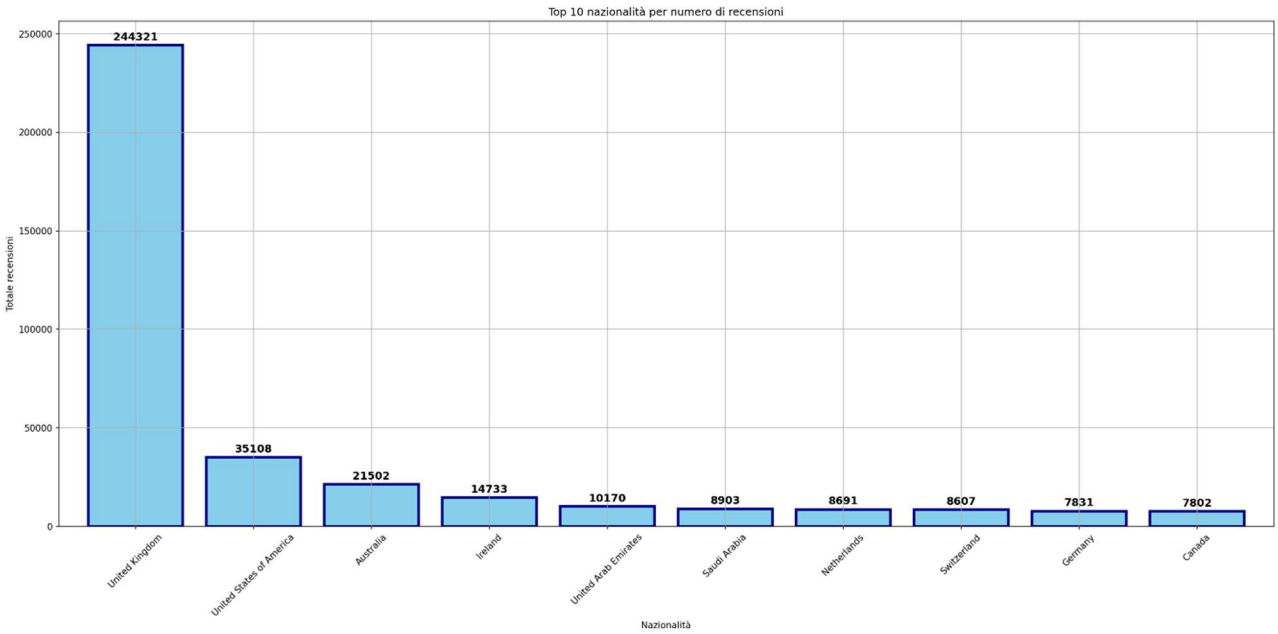

Figura 3. Bar chart top 10 nazionalità per recensioni

La visualizzazione delle nazionalità (*Figura 3*) rende palese la "Long Tail" del dataset: dopo il dominio assoluto del mercato UK, si nota un calo drastico dei volumi verso le altre nazioni. Tuttavia, la presenza di mercati come Emirati Arabi e Arabia Saudita nelle prime dieci posizioni sottolinea il respiro internazionale dell'offerta alberghiera analizzata.

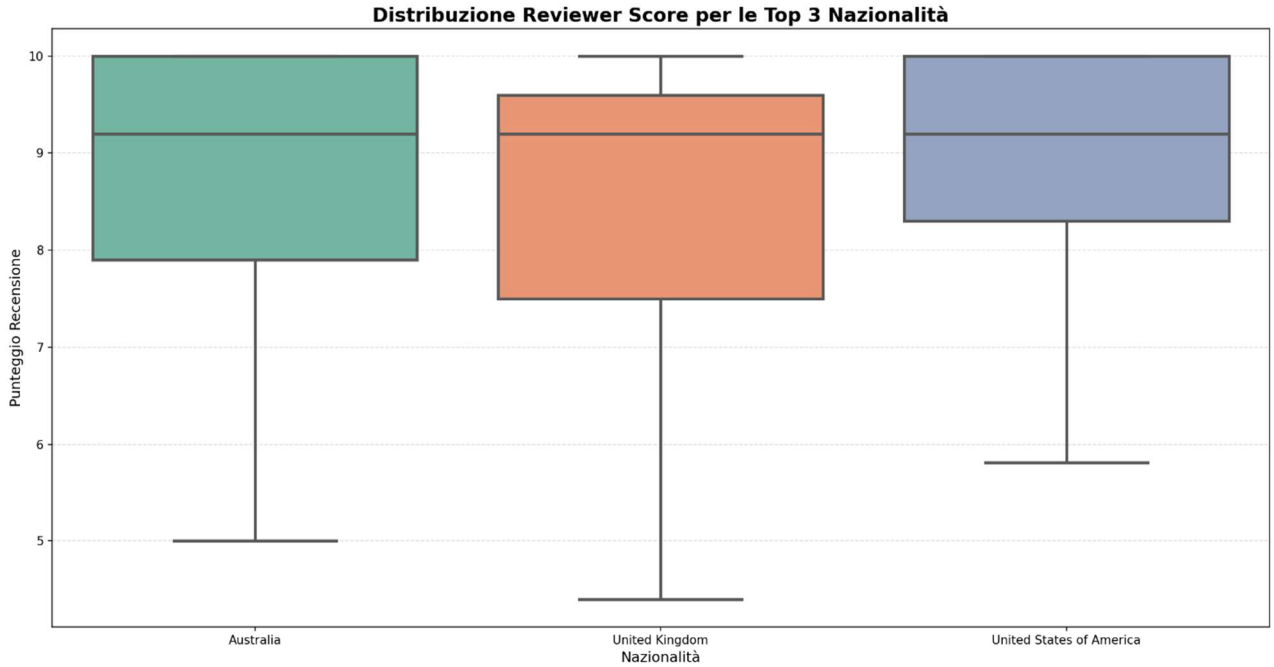

Figura 4. Box plot distribuzione Reviewer Score per nazionalità top 3

Attraverso il Box Plot (*Figura 4*), osserviamo come la distribuzione dei voti sia tendenzialmente spostata verso l'alto (mediana intorno a 9.2). Mentre i turisti USA mostrano un consenso molto compresso verso l'eccellenza, il mercato UK presenta una varianza maggiore, indicando una platea di viaggiatori più abituata a utilizzare l'intera scala dei voti, inclusi quelli più critici.

3.2.3 Performance Geografiche e Benchmark

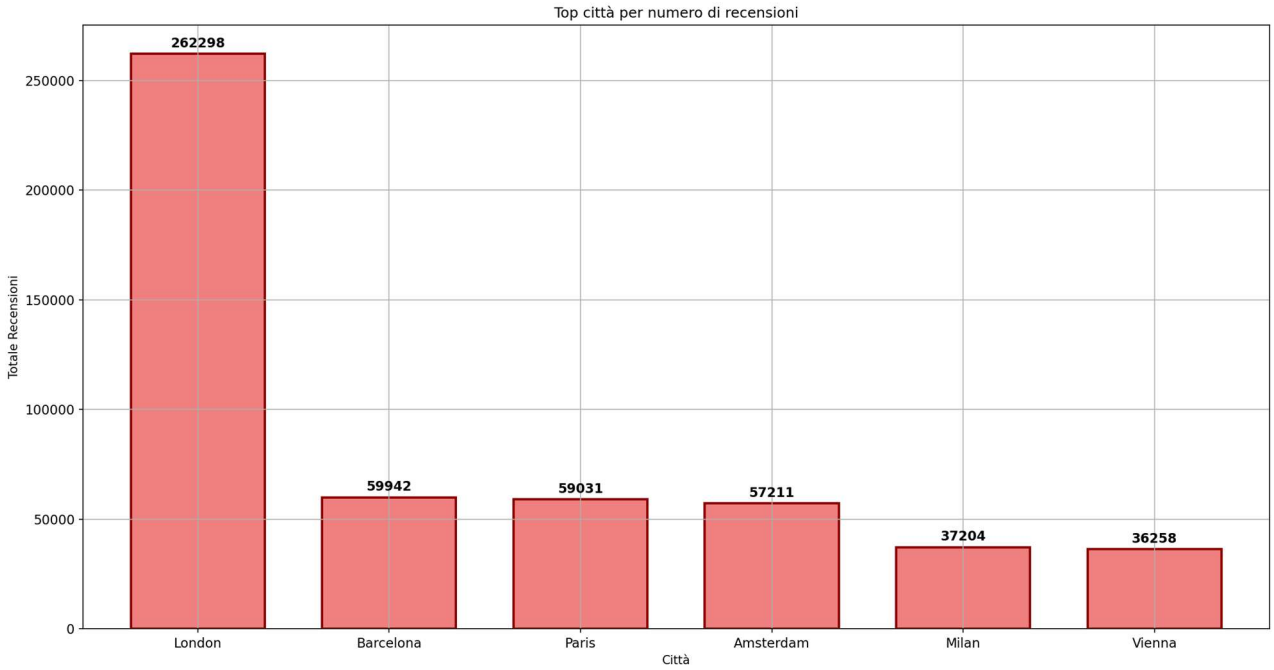

Figura 5. Bar chart top 10 città per numero recensioni

Il grafico delle città (*Figura 5*) ribadisce il primato volumetrico di Londra, ma evidenzia anche l'omogeneità tra Barcellona, Parigi e Amsterdam, che costituiscono il nucleo solido dell'offerta europea nel dataset.

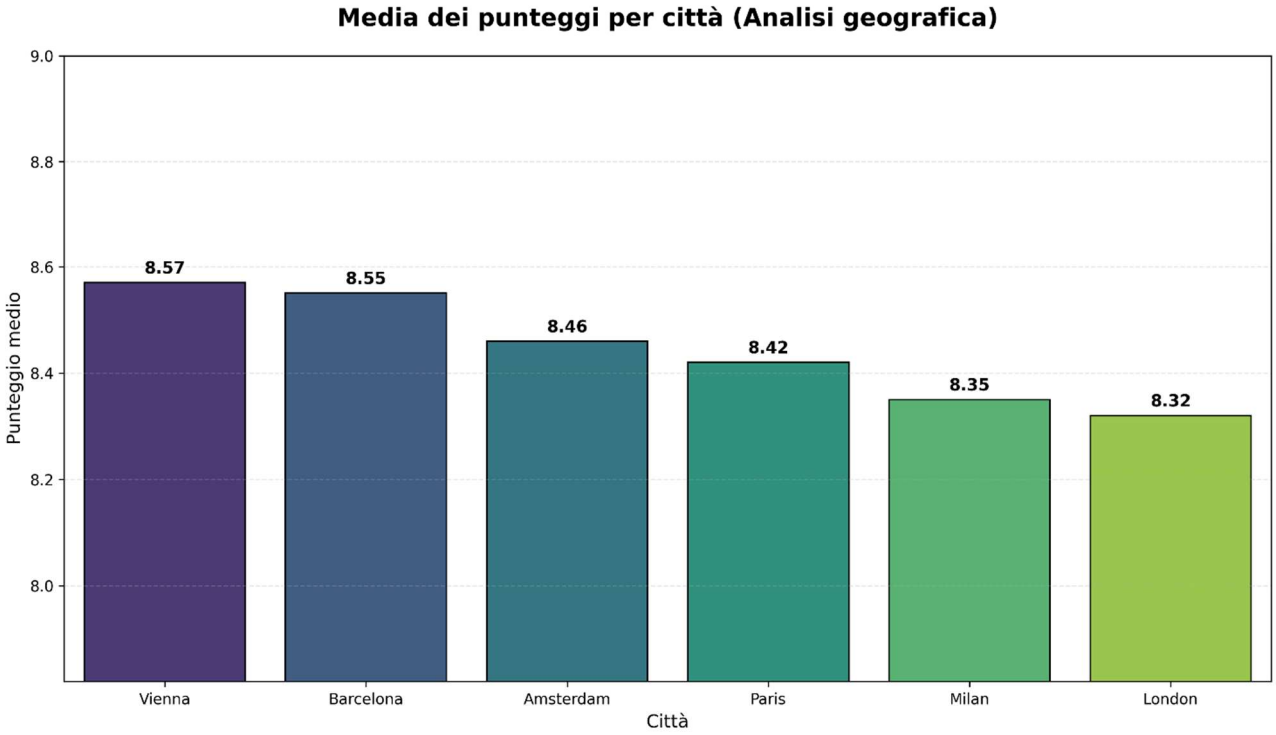

Figura 6. Bar chart score medio per top 10 città

Limitando l'asse delle ordinate, la *Figura 6* permette di apprezzare le micro-differenze qualitative: il primato di **Vienna** e la solidità di Barcellona emergono come casi studio di successo nella gestione dell'esperienza ospite, nonostante lo scarto minimo (0.25 punti) tra le diverse capitali.

3.2.4 Relazione tra Testo e Voto

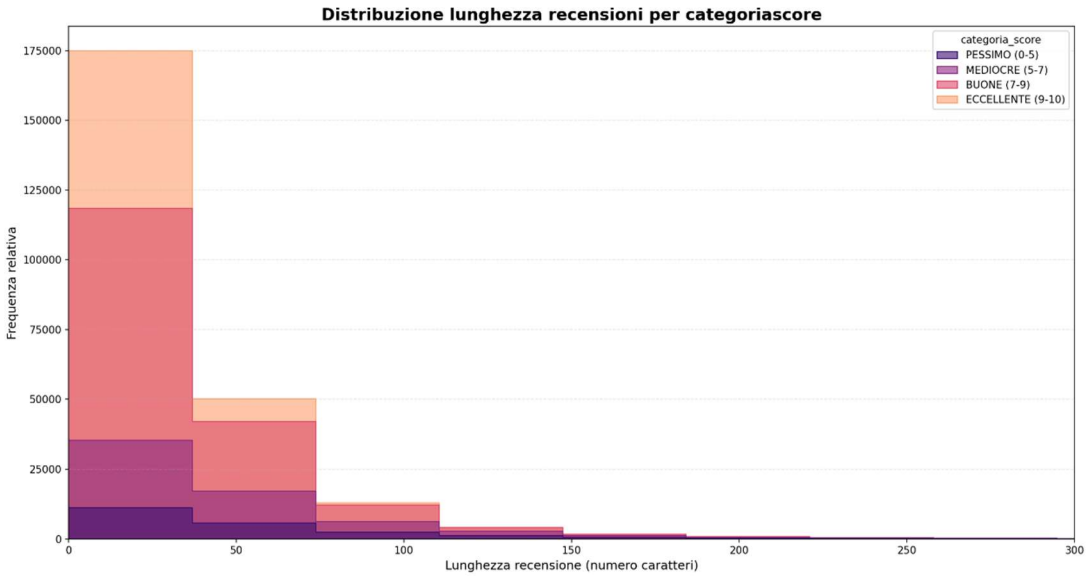

Figura 7. Istogramma Review Length per categoria score

L'istogramma della lunghezza dei testi (*Figura 7*) rivela una chiara asimmetria: i commenti "Eccellenti" sono brevi e puntuali, mentre i "Pessimi" mostrano una distribuzione più piatta e code più lunghe. Chi vive un'esperienza negativa sente il bisogno di argomentare il proprio dissenso con descrizioni minuziose.

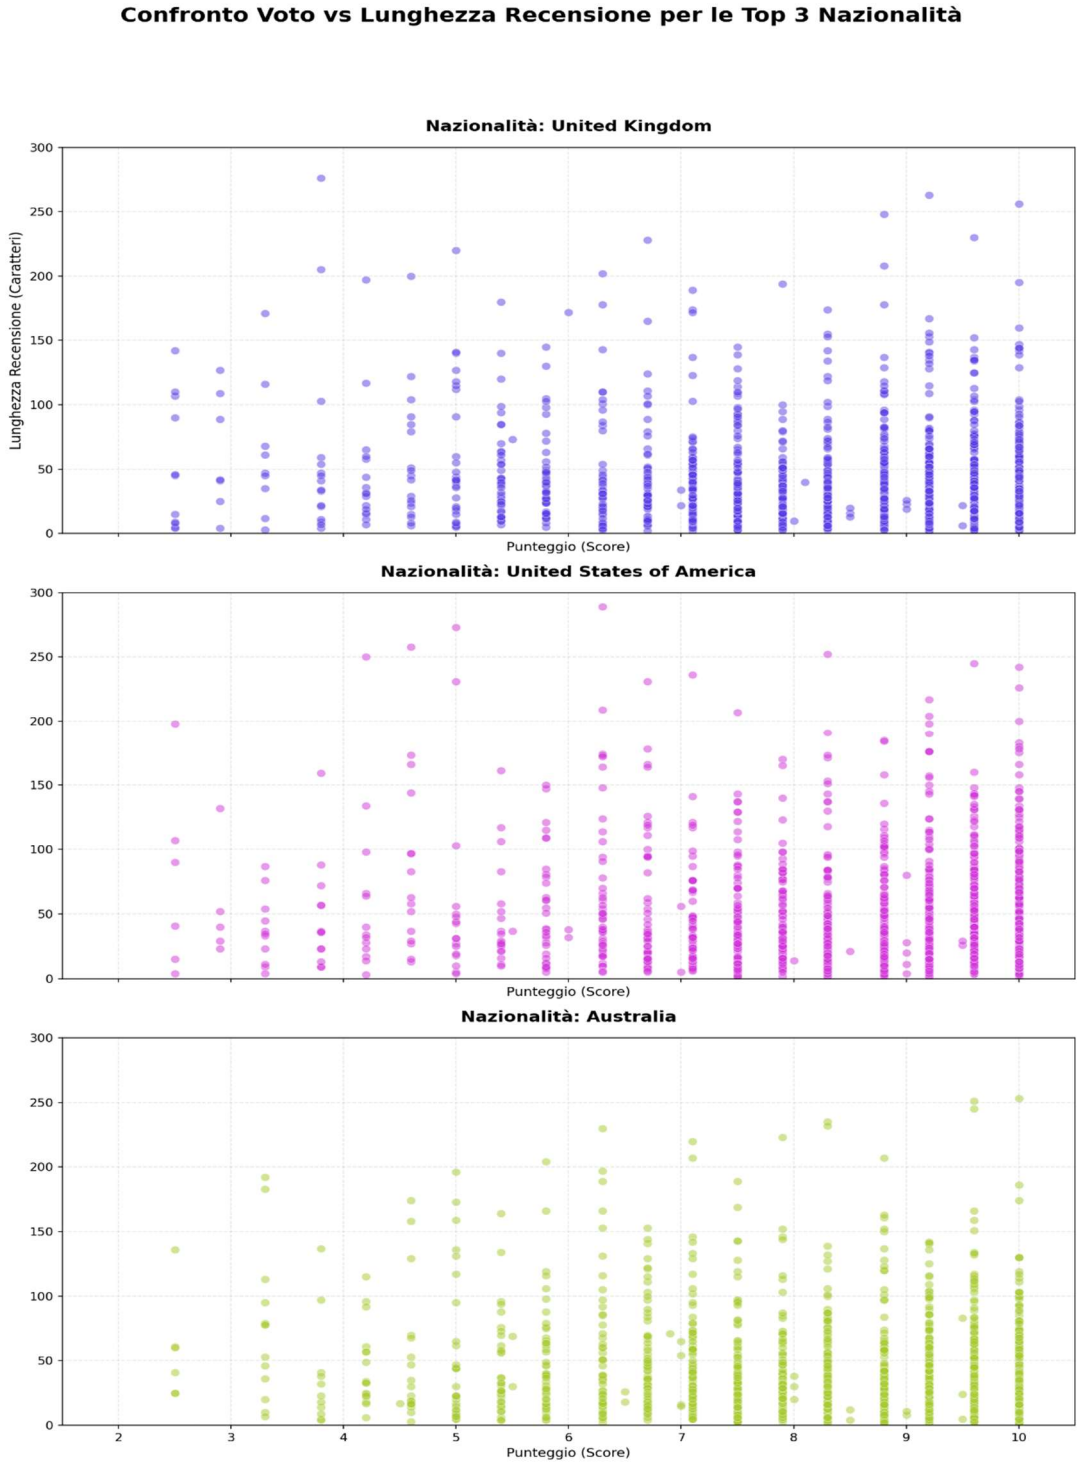

Figura 8. Scatter plot Review Length vs Reviewer Score

I sottografici verticali per UK, USA e Australia (*Figura 8*) validano l'universalità di questo comportamento. Indipendentemente dalla cultura di origine, la "nuvola" dei dati si addensa sistematicamente sui voti bassi quando la lunghezza del testo aumenta, confermando visivamente la correlazione negativa calcolata in precedenza.

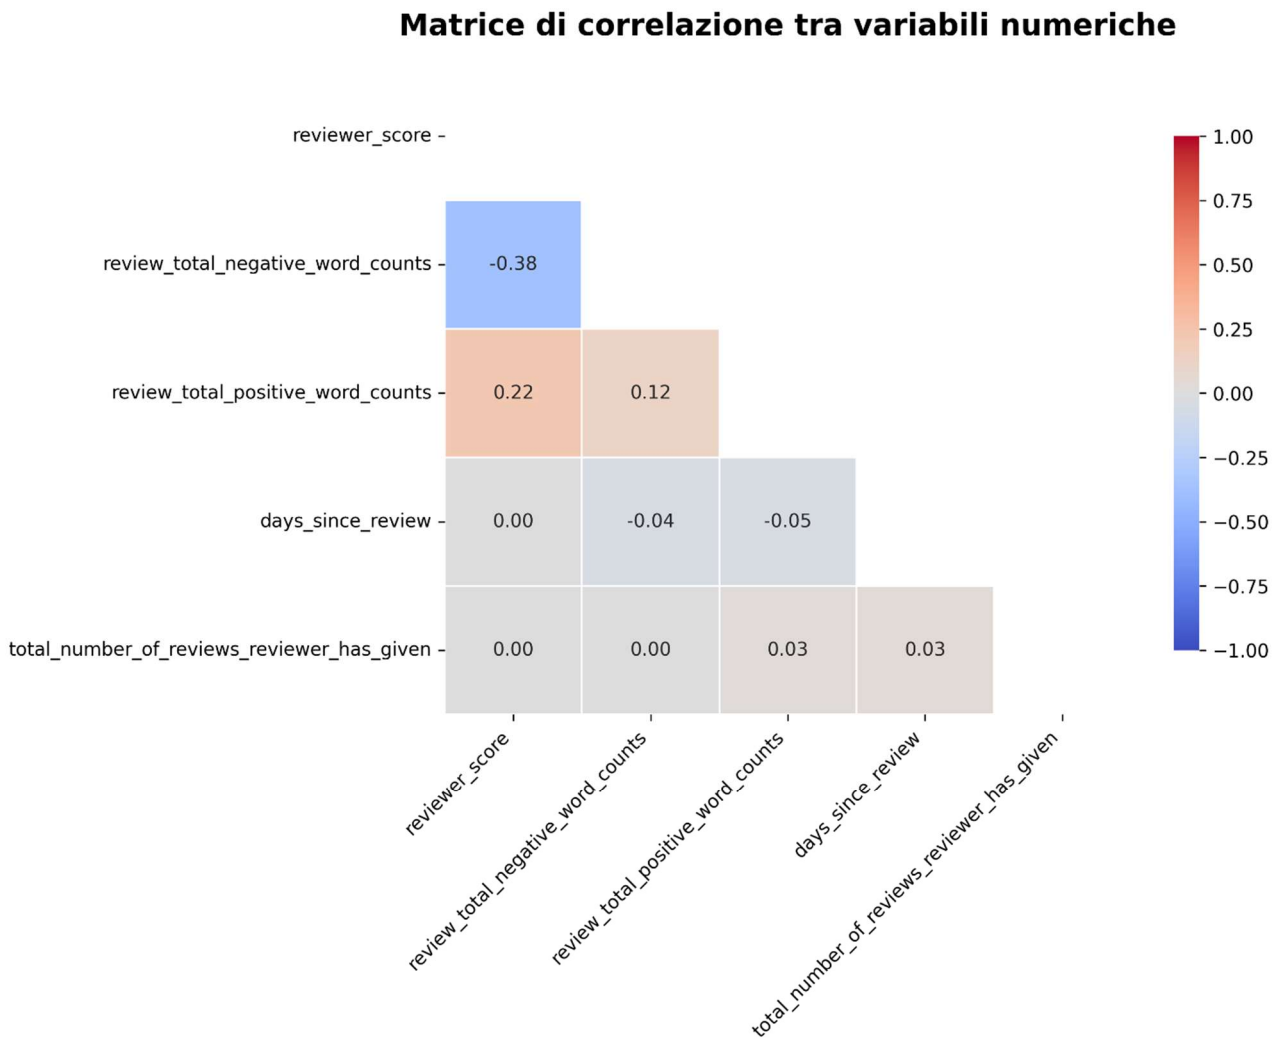

Figura 9. Heatmap correlazioni numeriche

A chiusura dell'analisi, la matrice di correlazione (*Figura 9*) ribadisce che il driver principale della verbosità è il sentiment negativo (-0.38), mentre altre variabili come l'esperienza pregressa del recensore o il tempo trascorso dalla recensione non mostrano impatti significativi sul punteggio finale.

4. Conclusioni Finali

L'analisi condotta sul dataset delle recensioni Booking.com ha permesso di individuare pattern strutturali e comportamentali rilevanti per la gestione strategica delle strutture alberghiere. I risultati evidenziano come la reputazione online non sia un fenomeno casuale, ma un sistema misurabile e governabile attraverso strumenti analitici.

Uno degli elementi più significativi riguarda la forte concentrazione geografica della domanda. Il mercato britannico emerge come dominante sia in termini di volumi sia di impatto sulla valutazione complessiva, influenzando in modo sostanziale la percezione globale delle strutture. Questo implica che le strategie di comunicazione e posizionamento dovrebbero essere calibrate tenendo conto delle aspettative e del comportamento di questo specifico segmento.

Dal punto di vista delle performance territoriali, l'analisi ha evidenziato come città con volumi inferiori, come Vienna e Barcellona, riescano a mantenere livelli di soddisfazione mediamente più

elevati rispetto a hub ad alta densità come Londra. Questo suggerisce che un'elevata pressione turistica può incidere sulla qualità percepita del servizio, rendendo necessario un maggiore controllo operativo nelle destinazioni ad alto traffico.

Un risultato particolarmente rilevante riguarda la relazione tra punteggio e lunghezza del feedback. La correlazione negativa conferma che gli utenti insoddisfatti tendono a esprimersi in modo più dettagliato e articolato. Questo insight può essere utilizzato per implementare sistemi di monitoraggio automatico delle recensioni, in cui commenti più lunghi vengono trattati come segnali precoci di criticità operative.

L'analisi temporale ha inoltre confermato la forte stagionalità del settore hospitality, con picchi concentrati nei mesi estivi. Tale dinamica implica che la gestione della reputazione deve essere intensificata nei periodi di alta domanda, quando il volume di feedback aumenta e il rischio reputazionale cresce proporzionalmente.

Sulla base di questi risultati, emergono alcune implicazioni operative per la gestione alberghiera:

- adattare le strategie di pricing e promozione ai picchi stagionali, sfruttando i momenti di alta domanda senza compromettere la qualità del servizio;
- sviluppare strategie di engagement mirate per i mercati principali, in particolare quello britannico;
- implementare sistemi di alert basati sulla lunghezza e sul contenuto delle recensioni per individuare tempestivamente eventuali criticità;
- monitorare costantemente il gap tra punteggio medio storico e valutazioni recenti, al fine di intercettare variazioni nella customer satisfaction.

In conclusione, il progetto dimostra come l'integrazione tra strumenti di data analysis (SQL e Python) e approcci di data visualization consenta di trasformare dati grezzi in informazioni strategiche. La gestione efficace della reputazione online si configura quindi come una leva competitiva fondamentale, in grado di influenzare direttamente le performance economiche e il posizionamento delle strutture nel mercato hospitality.